


参数重要性研究

后续工作流程与阶段计划




上海交通大学


2026 年 8 月 20 日

一个高分参数，真的更重要吗？

观察到的排序




还缺哪一步



分数与功能之间还隔着一步

随机梯度噪声、数值近似和训练路径都可能改写排序。只有干预参数并观察任务损伤，才能判断它有没有功能含义。


Stage 1-9: 证据怎样一步步补齐



章节 本章要解决的问题

- 一 定义中的量，是否真的算对了？
 - 二 方法放到更大模型上，还能跑通整个研究闭环吗？
 - 三 重要性结构能否解释训练差异，并预测剪枝损伤？
 - 四 结论经得住消融吗，证据能否逐项复核？
-

第一章 | 先把测量做实



实现、统计和数值误差分开核验，后面的解释才站得住。

Stage 1 | 我们到底在估计什么?

固定参数状态下的局部梯度空间贡献

$$\hat{c}_{k,t}^U = \eta_{g(k),t} \frac{S_{1,k,t}^2 - S_{2,k,t}}{M(M-1)}$$

- $S_{1,k,t}$: M 个 microbatch 梯度之和
- $S_{2,k,t}$: 对应梯度平方和
- 去除对角项: 目标指向总体梯度平方

M 个 microbatch
梯度 $g_{1,k}, \dots, g_{M,k}$

充分统计量
 S_1, S_2

去对角 U-statistic
 $\hat{c}_{k,t}^U$

与参数绝对值、移动
量、raw 分数并列比较

这一阶段只核对实现是否忠实; 模型机理留到后面讨论。

Stage 1 | 用独立对照逐层核验实现



核验层	主要比较对象	要排除的错误
梯度尺度	完整 batch vs. microbatch	loss reduction / token 权重
估计器内核	显式成对式 vs. 流式式	对角项、分母、权重
训练接线	开启统计 vs. 关闭统计	训练轨迹被扰动
并行语义	相同 global batch	聚合与累积尺度漂移

每个张量都要过独立 oracle; 只看全局总和, 局部错误很容易被抵消。

Stage 1 | double 与 U 怎样消掉同源偏差?

偏差来自对角项: 同一个随机梯度与自己相乘, 会额外带入方差。

double sample | 换成两组独立梯度


$$\begin{aligned}\widehat{\mu_k^2}^{\text{double}} &= \bar{g}_k^{(A)} \bar{g}_k^{(B)}, \\ \mathbb{E}[\widehat{\mu_k^2}^{\text{double}}] &= \mu_k^2\end{aligned}$$

- A、B 独立: 乘积期望可拆开
- 代价: 需要两组独立梯度

U-statistic | 在同一梯度池中删掉对角项

$$\begin{aligned}\widehat{\mu_k^2}^U &= \frac{\sum_{m \neq n} g_{m,k} g_{n,k}}{M(M-1)}, \\ &= \frac{S_{1,k}^2 - S_{2,k}}{M(M-1)}\end{aligned}$$

- S_1^2 含全部两两乘积, S_2 正好是自乘项
- 复用同一梯度池; 单次估计可能为负




两种方法都把“随机梯度自乘”换成“独立梯度交叉相乘”。

Stage 2 | raw 为什么会系统性过估计?

同一批数据同时提供两个梯度因子

$$\mathbb{E}[\bar{g}_k^2] = \mu_k^2 + \frac{\sigma_k^2}{B}$$

- 目标: μ_k^2
- 额外项: 同源随机梯度方差
- 预测: 正偏随 batch size 按 $1/B$ 衰减




图示表达预注册理论趋势，不代表已有结果。

Stage 2 先把梯度噪声带来的偏差从真实信号里剥离出来。

Stage 2 | 同一预算下比较三种估计器

方法	梯度因子来源	偏差预期	主要代价
raw	同一批样本	正偏	最低
double sample	两个独立半区	无偏	两组梯度
U-statistic	同一梯度池去对角	无偏	维护充分统计量




最终选择同时看统计效率和真实成本，形式上的无偏还不够。

固定更新前后端点与独立 probe 损失

$$\Gamma_t(\alpha) = \Theta_t + \alpha \Delta \Theta_t,$$

$$C_{k,t}^{\text{path}, \mathcal{P}} = -\Delta \theta_{k,t} \int_0^1 \partial_k \mathcal{L}_{\mathcal{P}}(\Gamma_t(\alpha)) d\alpha.$$

- 同一线性路径、同一确定性 probe
- 实际端点位移已包含优化器作用
- 不再额外乘学习率或裁剪因子




完备性检查

$$\sum_k C_{k,t} = \mathcal{L}_{\mathcal{P}}(\Theta_t) - \mathcal{L}_{\mathcal{P}}(\Theta_{t+1})$$

Stage 3 | 用最少梯度节点满足精度要求

同一条路径上的候选节点（示意）




规则	节点	成本
左端点	1	最低
梯形	2	低
Simpson	3	中
复合/GL	多节点	参考级

完备性 + 向量误差
排序 + top- q + 层级稳定

在通过者中
选择梯度求值最少者


最后给出一个默认方案；若精度不够，再按预设顺序增加节点。

第二章 | 把方法放进完整研究闭环



规模扩大检验的是同一套证据能否继续成立。

Stage 4 | 160M: 先跑通一轮完整研究



这一轮要看清


- 能否边训练边稳定记录重要性
- 这些统计能否支撑结构分析和剪枝
- 两条路线是否真的从同一起点出发

暂时不下结论

- 最终规模结论留给后续实验
- 一次剪枝曲线只作流程校验
- 估计器和求积沿用前章选择

160M 的任务是暴露流程问题，为后续放大扫清障碍。

Stage 4 | 统一初始化下的两条路线



固定条件	唯一核心差异	第一轮输出
架构、初始化、评价任务	是否经历语言模型预训练	可比较的闭环证据

先确认对照公平；410M 阶段再检验路线差异是否稳定。


Stage 5 | 410M: 追踪重要性如何逐步形成

训练初期多留观察点，随后逐步拉开间隔



每个观察点	沿时间聚合	要回答的问题
loss、梯度范数、更新范数 raw、U、signed/positive/negative 参数移动量与 top-k	层/模块重要性 集中度与有效参数数 集合稳定性	哪些结构先分化？ 重要性是否越来越集中？ 关键参数何时稳定？


Stage 5 | 长轨迹最后落成三类结构图



所有图均为计划输出结构示意；正式数值由 Stage 5 实验产生。


把逐参数长向量整理成可比较的动态结构。

第三章 | 训练差异是否对应功能差异



结构差异先提出解释，剪枝实验再看它有没有功能后果。

Stage 6 | 两条训练路线，起点和预算都要对齐




任务角色	主要用途	压力维度
SST-2	稳定二分类对照	清晰、低噪声
MNLI	主要自然语言推理	规模与泛化
RTE	低资源压力测试	样本效率

Stage 6 | 性能变化和参数结构要一起看


任务表现

- 最终任务性能与置信区间
- 收敛速度与样本效率
- 多 seed 稳定性与泛化差异



参数结构

- 重要性分布与层/模块分工
- 集中度与有效参数数量
- 预训练 top-k 在微调中的复用



曲线仅说明计划比较的形态，不预设哪条路线更优。

Stage 7 | 用同一套预算做剪枝对照

重要性来源 × 剪除方向

	高重要性	低重要性	随机
magnitude			
movement			
raw			
U or double			
Fisher			
SI			

每个组合都要覆盖

- 多个剪枝比例
- 全局与层内平衡
- 多随机 mask
- 语言模型与下游任务


冻结排序

临时应用 mask

评价任务损伤

预算、任务和剪枝比例全部对齐，唯一变化是排序规则。

Stage 7 | 什么样的剪枝曲线才有说服力？




满足这些条件才算通过

- 高重要性曲线显著更陡
- 低重要性优于随机基线
- 多比例下顺序稳定
- AUC 差异带置信区间

解释边界


曲线不分离：仅保留描述性用途；
不宣称功能有效。

第四章 | 先划边界，再整理证据



跨因素仍稳定的结果，才值得写进主结论。

Stage 8 | 一次只动一个条件



这样做能看清什么

- 父子实验共享其余条件
- 效应可归因于注册因素
- 避免组合变化掩盖根因


矩阵先定，结果后看

所有组合按同一规则汇总；没有运行过的组合不作外推。

消融要找出结论成立所需的条件，实验数量本身没有意义。

Stage 8 | 敏感性结果最终要写成适用边界

相对基准的效应与不确定性 (判读示意)



点和区间仅示意最终图形语法, 不预设真实效应。

多项因素下都稳定
可作为默认结论


只对部分条件稳定
写明使用条件

关键结论发生反转
缩小适用范围

最终要交代

推荐设置、适用范围、局限, 以及尚未覆盖的组合。


Stage 9 | 把零散结果整理成一套证据



证据问题	统一统计	典型输出
估计器是否可靠	Bias / Variance / MSE	校准图与比较表
排序是否稳定	Pearson / Spearman / top-k	稳定性曲线
重要性是否集中	Gini / entropy / HHI	层/模块热力图
重要性是否有功能	损伤 AUC / 配对区间	剪枝曲线

所有图表都从同一份结果表生成，研究者负责解释。

Stage 9 | 每句话都要找到证据出处




结论怎么写

只写证据能够支持的范围：支持、不支持，或目前证据不足。判据不随结果方向改变。

Stage 9 结束时，论文里的每项结论都能沿表、图和统计定义回溯。

关键路径 | 什么时候可以进入下一阶段?



关键转折	放行依据	未通过时
S2 → S3	选出可靠主估计器	回到参考与估计器诊断
S3 → S4	选出默认求积方案	增加节点或收缩适用范围
S4 → S5	160M 闭环完整	修正流程，不直接放大
S7 → S8	功能损伤证据成立	保留描述性结论

一路上需要做出的五个选择

序号	决策	主要证据	输出
1	主估计器	Bias / MSE / 排序 / 成本	U 或 double
2	默认求积	完备性 / 向量误差 / 节点成本	左端点、梯形或更高阶
3	是否规模化	160M 完整闭环	进入 410M 轨迹
4	是否具备功能含义	高/低/随机剪枝损伤	功能有效或仅描述性
5	结论强度	单因素消融与跨 seed 稳定性	默认、条件化或收缩



证据达到门槛就继续；达不到，就回到对应环节补足。

最后记住三件事

1

把三类误差拆开

实现误差




统计偏差



数值误差

2

沿训练过程看结构怎么形成



3

用功能干预限定解释

重要性排序



定向剪枝



任务损伤

整项研究要把定义、估计、轨迹、干预和稳健性接成一条可核验的链。



Parameter Importance Project.

参数重要性研究实验计划与统一数学规格.

[Internal research documents](#), 2026.



W. Hoeffding.

A Class of Statistics with Asymptotically Normal Distribution.

[The Annals of Mathematical Statistics](#), 19(3):293–325, 1948.



M. Sundararajan, A. Taly, and Q. Yan.

Axiomatic Attribution for Deep Networks.

[ICML](#), PMLR 70:3319–3328, 2017.



S. Biderman et al.

Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling.

[ICML](#), PMLR 202:2397–2430, 2023.




P. Molchanov et al.

Importance Estimation for Neural Network Pruning.

[CVPR](#), 11264–11272, 2019.

**参数重要性的形成过程，
能否成为连接优化动态与泛化能力的中间表征？**



感谢聆听·Q&A

备份材料 | 常见追问



什么时候用

遇到公式、权重、完备性或指标口径问题时，再跳到对应页面。

备份 | raw 正偏从哪里来？

为什么同一个 minibatch 的平均梯度平方不是 μ_k^2 ？

$$\bar{g}_k = \frac{1}{B} \sum_{i=1}^B g_k(z_i),$$

$$\mathbb{E}[\bar{g}_k] = \mu_k,$$

$$\mathbb{E}[\bar{g}_k^2] = \text{Var}(\bar{g}_k) + \mathbb{E}[\bar{g}_k]^2,$$

$$\text{Var}(\bar{g}_k) = \frac{\sigma_k^2}{B},$$

$$\Rightarrow \mathbb{E}[\bar{g}_k^2] = \mu_k^2 + \frac{\sigma_k^2}{B}.$$

标量例子

$$\mu = 2, \quad \sigma^2 = 9, \quad B = 9 \Rightarrow \mathbb{E}[\bar{g}^2] = 5$$

判别预测

- 真目标: $\mu^2 = 4$
- raw 额外增加 1
- B 增大时偏差按 $1/B$ 衰减

double sample 和 U-statistic 都是在去掉同源对角项。

等权 microbatch

$$\widehat{\mu_k^2}^U = \frac{S_{1,k}^2 - S_{2,k}}{M(M-1)} = \frac{1}{M(M-1)} \sum_{m \neq n} g_{m,k} g_{n,k}$$

- $S_{1,k} = \sum_m g_{m,k}$
- $S_{2,k} = \sum_m g_{m,k}^2$
- $M \geq 2$; 交换顺序结果不变

不等有效 token 数

$$\widehat{\mu_k^2}^{U_w} = \frac{G_{1,k}^2 - G_{2,k}}{N_1^2 - N_2}$$

- $G_{1,k} = \sum_m b_m g_{m,k}$
- $G_{2,k} = \sum_m b_m^2 g_{m,k}^2$
- $N_1 = \sum_m b_m, \quad N_2 = \sum_m b_m^2$

一致性检查

当所有 b_m 相等时，加权式退化为等权式；分母必须严格为正。

权重应与训练损失的统计单位一致；microbatch 不能默认等权。

备份 | 路径积分的完备性从哪里来？

固定线性路径 $\Gamma(\alpha) = \Theta_0 + \alpha\Delta\Theta$ **与标量损失** $\mathcal{L}$ 。

$$\frac{d}{d\alpha}\mathcal{L}(\Gamma(\alpha)) = \nabla_{\Theta}\mathcal{L}(\Gamma(\alpha))^{\top}\Delta\Theta,$$

$$\mathcal{L}(\Theta_1) - \mathcal{L}(\Theta_0) = \int_0^1 \sum_k \partial_k \mathcal{L}(\Gamma(\alpha)) \Delta\theta_k d\alpha.$$

定义 $C_k^{\text{path}} = -\Delta\theta_k \int_0^1 \partial_k \mathcal{L}(\Gamma(\alpha)) d\alpha$, 则

$$\sum_k C_k^{\text{path}} = \mathcal{L}(\Theta_0) - \mathcal{L}(\Theta_1)$$



备份 | 这些指标各自回答什么？

指标	回答的问题	主要使用阶段
Bias	估计均值偏离参考多少？	Stage 2
Variance / MSE	重复波动与综合误差多大？	Stage 2
Pearson / Spearman	数值或排序是否一致？	Stage 2–3
top- <i>k</i> overlap	关键参数集合是否恢复？	Stage 2–6
Gini / entropy	重要性分布是否集中？	Stage 5–8
HHI / 有效参数数	质量由多少参数承载？	Stage 5–8
Damage AUC	剪枝全过程造成多少功能损伤？	Stage 7
配对置信区间	路线或配置差异是否稳定？	Stage 6–9

统计单位

参数坐标用于分布与排序，不充当独立重复；置信区间以 repetition、checkpoint、模型或 seed 为单位。

相关性、集中度和功能损伤各答各的问题，不能互相替代。