


参数重要性研究


后续工作流程与阶段计划




2026 年 8 月 20 日

核心研究问题 | 数值排序能否代表功能重要性？

观察到的排序




尚需补充的功能证据



从数值排序到功能结论

随机梯度噪声、数值近似和训练路径均可能改变排序。只有对参数实施受控干预并测量任务损伤，才能判断排序是否反映功能差异。


Stage 1-9 | 从数值估计到功能证据



章节 本章要解决的问题

- 一 目标量、估计器与路径积分是否满足可信度要求？
 - 二 完整分析流程能否扩展至更大模型与更长训练轨迹？
 - 三 重要性结构能否解释训练差异并预测剪枝损伤？
 - 四 主要结论是否稳健，且能够由证据逐项复核？
-

第一章 | 测量可信度：实现、统计与数值核验



分别核验实现误差、统计误差与数值误差，构成后续解释的可信度基础。

Stage 1 | 局部梯度空间贡献的估计目标

固定参数状态下的局部梯度空间贡献

$$\hat{c}_{k,t}^U = \eta_{g(k),t} \frac{S_{1,k,t}^2 - S_{2,k,t}}{M(M-1)}$$

- $S_{1,k,t}$: M 个 microbatch 梯度之和
- $S_{2,k,t}$: 对应梯度平方和
- 去除对角项: 目标指向总体梯度平方

M 个 microbatch
梯度 $g_{1,k}, \dots, g_{M,k}$

充分统计量
 S_1, S_2

去对角 U-statistic
 $\hat{c}_{k,t}^U$

与参数绝对值、移动
量、raw 分数并列比较

本阶段验证实现与数学定义的一致性，不据此推断模型机制。

Stage 1 | 以独立参考逐层核验实现



核验层	主要比较对象	要排除的错误
梯度尺度	完整 batch vs. microbatch	loss reduction / token 权重
估计器内核	显式成对式 vs. 流式式	对角项、分母、权重
训练接线	开启统计 vs. 关闭统计	训练轨迹被扰动
并行语义	相同 global batch	聚合与累积尺度漂移

逐张量对照独立 oracle, 避免聚合结果掩盖局部实现误差。

Stage 1 | double sample 与 U-statistic 的无偏化机制

偏差来源：同一随机梯度的自乘项将抽样方差并入目标。

double sample | 独立样本组交叉相乘


$$\begin{aligned}\widehat{\mu_k^2}^{\text{double}} &= \bar{g}_k^{(A)} \bar{g}_k^{(B)}, \\ \mathbb{E}[\widehat{\mu_k^2}^{\text{double}}] &= \mu_k^2\end{aligned}$$

- A、B 独立：乘积期望可分解
- 代价：需要两组独立梯度

U-statistic | 删除同一样本的自乘项

$$\begin{aligned}\widehat{\mu_k^2}^U &= \frac{\sum_{m \neq n} g_{m,k} g_{n,k}}{M(M-1)}, \\ &= \frac{S_{1,k}^2 - S_{2,k}}{M(M-1)}\end{aligned}$$

- S_1^2 包含全部两两乘积， S_2 为自乘项之和
- 复用同一梯度池；单次估计可能为负




两种估计器均以独立交叉乘积替代同一样本的随机梯度自乘。

Stage 2 | raw estimator 的系统性正偏

同一批数据同时提供两个梯度因子

$$\mathbb{E}[\bar{g}_k^2] = \mu_k^2 + \frac{\sigma_k^2}{B}$$

- 目标: μ_k^2
- 额外项: 同一样本梯度的抽样方差
- 预测: 正偏随 batch size 按 $1/B$ 衰减




图示表达预注册理论趋势，不代表已有结果。

Stage 2 量化抽样方差造成的正偏，并检验其随 batch size 的衰减规律。

Stage 2 | 等计算预算下的估计器比较

方法	梯度因子来源	偏差预期	主要代价
raw	同一批样本	正偏	最低
double sample	两个独立半区	无偏	两组梯度
U-statistic	同一梯度池去对角	无偏	维护充分统计量




主估计器的选择同时依据统计误差、排序恢复能力与实际计算成本。

固定更新前后端点与独立 probe 损失

$$\Gamma_t(\alpha) = \Theta_t + \alpha \Delta \Theta_t,$$

$$C_{k,t}^{\text{path}, \mathcal{P}} = -\Delta \theta_{k,t} \int_0^1 \partial_k \mathcal{L}_{\mathcal{P}}(\Gamma_t(\alpha)) d\alpha.$$

- 同一线性路径、同一确定性 probe
- 实际端点位移已包含优化器作用
- 不再额外乘学习率或裁剪因子




完备性检查

$$\sum_k C_{k,t} = \mathcal{L}_{\mathcal{P}}(\Theta_t) - \mathcal{L}_{\mathcal{P}}(\Theta_{t+1})$$

Stage 3 | 求积精度与梯度计算成本

同一条路径上的候选节点（示意）




规则	节点	成本
左端点	1	最低
梯形	2	低
Simpson	3	中
复合/GL	多节点	参考级

完备性 + 向量误差
排序 + top- q + 层级稳定

在通过者中
选择梯度求值最少者

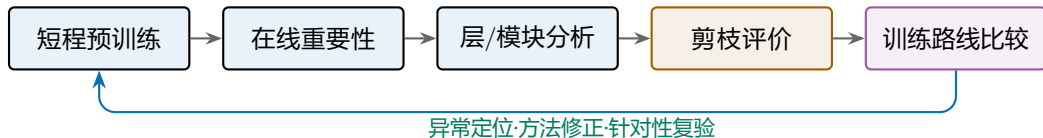
在满足预注册精度标准的候选规则中，选择梯度求值次数最少者。

第二章 | 规模扩展与纵向轨迹分析



规模扩展用于检验同一测量与分析框架能否保持有效。

Stage 4 | 160M 模型的端到端流程验证



流程验证内容


- 训练期间能否稳定记录重要性
- 统计量能否支持结构分析与剪枝
- 训练路线是否满足受控配对条件

本阶段的结论边界

- 不据此形成最终规模结论
- 单次剪枝曲线仅用于流程校验
- 估计器和求积沿用前章选择

160M 阶段用于验证流程完整性，并识别规模扩展前的系统性问题。

Stage 4 | 受控训练路线的初步对照



固定条件	唯一核心差异	第一轮输出
架构、初始化、评价任务	是否经历语言模型预训练	可比较的流程证据

本阶段核验配对设计，路线差异的稳定性由后续多任务实验检验。


Stage 5 | 410M 模型的训练期重要性轨迹

训练早期采用密集测量，随后增加相邻 checkpoint 的间隔



每个测量点	时间序列聚合	研究问题
loss、梯度范数、更新范数 raw、U、signed/positive/negative 参数移动量与 top-k	层/模块重要性 集中度与有效参数数 集合稳定性	哪些结构先分化？ 重要性是否越来越集中？ 关键参数何时稳定？


Stage 5 | 训练轨迹的三类动态结构表征



所有图均为计划输出结构示意；正式数值由 Stage 5 实验产生。


将逐参数时间序列转化为层级结构、集中度与集合稳定性表征。

第三章 | 训练路线差异与功能性验证



训练路线比较提出结构假设，定向剪枝检验其功能后果。

Stage 6 | 训练路线的受控配对设计




任务角色	主要用途	压力维度
SST-2	稳定二分类对照	清晰、低噪声
MNLI	主要自然语言推理	规模与泛化
RTE	低资源压力测试	样本效率

Stage 6 | 任务性能与参数结构的联合比较


任务表现

- 最终任务性能与置信区间
- 收敛速度与样本效率
- 多 seed 稳定性与泛化差异



参数结构

- 重要性分布与层/模块分工
- 集中度与有效参数数量
- 预训练 top-k 在微调中的复用



曲线仅说明计划比较的形态，不预设哪条路线更优。

Stage 7 | 等预算的定向剪枝对照设计

重要性来源 × 剪除方向

	高重要性	低重要性	随机
magnitude			
movement			
raw			
U or double			
Fisher			
SI			

每个组合都要覆盖

- 多个剪枝比例
- 全局与层内平衡
- 多随机 mask
- 语言模型与下游任务


冻结排序

临时应用 mask

评价任务损伤

固定评价预算、任务与剪枝比例，仅改变参数排序及剪除方向。

Stage 7 | 剪枝曲线的功能性判定标准




预注册通过条件

- 高重要性曲线显著更陡
- 低重要性优于随机基线
- 多比例下顺序稳定
- AUC 差异带置信区间


解释边界

曲线不分离：仅保留描述性用途；
不宣称功能有效。

第四章 | 稳健性分析与证据整合



仅将跨关键因素保持稳定的结果纳入主要结论。



单因素设计的作用

- 父子实验共享其余条件
- 效应可归因于注册因素
- 避免组合变化掩盖根因


矩阵先定，结果后看

所有组合按同一规则汇总；没有运行过的组合不作外推。

消融分析用于识别结论成立的必要条件，而非单纯增加实验数量。

Stage 8 | 敏感性分析与结论适用范围

相对基准的效应与不确定性 (判读示意)



点和区间仅示意最终图形语法, 不预设真实效应。

多项因素下都稳定
可作为默认结论


只对部分条件稳定
写明使用条件

关键结论发生反转
缩小适用范围

最终要交代

推荐设置、适用范围、局限, 以及尚未覆盖的组合。


Stage 9 | 统一统计分析与结果整合



证据问题	统一统计	典型输出
估计器是否可靠	Bias / Variance / MSE	校准图与比较表
排序是否稳定	Pearson / Spearman / top-k	稳定性曲线
重要性是否集中	Gini / entropy / HHI	层/模块热力图
重要性是否有功能	损伤 AUC / 配对区间	剪枝曲线

所有论文图表由统一结果表生成，并使用一致的统计定义与分析单位。

Stage 9 | 结论—证据映射与结论强度




结论表述原则

只写证据能够支持的范围：支持、不支持，或目前证据不足。判据不随结果方向改变。

每项论文结论均应回溯至相应实验、图表、统计定义与不确定性说明。


关键路径 | 阶段推进的科学判定条件



关键转折	推进依据	未满足时的处理
S2 → S3	选出可靠主估计器	复核参考与估计器诊断
S3 → S4	选出默认求积方案	增加节点或收缩适用范围
S4 → S5	160M 流程完整	修正受影响环节，暂缓扩展
S7 → S8	功能损伤证据成立	保留描述性结论

五项预注册科学决策

序号	决策	主要证据	输出
1	主估计器	Bias / MSE / 排序 / 成本	U 或 double
2	默认求积	完备性 / 向量误差 / 节点成本	左端点、梯形或更高阶
3	是否规模化	160M 完整验证流程	进入 410M 轨迹
4	是否具备功能含义	高/低/随机剪枝损伤	功能有效或仅描述性
5	结论强度	单因素消融与跨 seed 稳定性	默认、条件化或收缩



每项决策均依据预注册证据门槛，并保留未满足条件时的替代结论。

研究设计的三个核心原则

1

区分三类误差来源

实现误差




统计偏差



数值误差

2

分析结构的形成过程



3

用功能干预限定解释

重要性排序



定向剪枝



任务损伤

定义、估计、训练轨迹、功能干预与稳健性共同构成可核验的证据体系。



Parameter Importance Project.

参数重要性研究实验计划与统一数学规格.

[Internal research documents](#), 2026.



W. Hoeffding.

A Class of Statistics with Asymptotically Normal Distribution.

[The Annals of Mathematical Statistics](#), 19(3):293–325, 1948.



M. Sundararajan, A. Taly, and Q. Yan.

Axiomatic Attribution for Deep Networks.

[ICML](#), PMLR 70:3319–3328, 2017.



S. Biderman et al.

Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling.

[ICML](#), PMLR 202:2397–2430, 2023.




P. Molchanov et al.

Importance Estimation for Neural Network Pruning.

[CVPR](#), 11264–11272, 2019.

**参数重要性的形成过程，
能否成为连接优化动态与泛化能力的中间表征？**



感谢聆听·Q&A

技术细节与判读口径



附录内容

包括 raw 正偏、U-statistic 权重、路径完备性及统计指标的正式定义。

附录 | raw estimator 正偏的二阶矩分解

同一 minibatch 的平均梯度平方为何不等于 μ_k^2 ?

$$\bar{g}_k = \frac{1}{B} \sum_{i=1}^B g_k(z_i),$$

$$\mathbb{E}[\bar{g}_k] = \mu_k,$$

$$\mathbb{E}[\bar{g}_k^2] = \text{Var}(\bar{g}_k) + \mathbb{E}[\bar{g}_k]^2,$$

$$\text{Var}(\bar{g}_k) = \frac{\sigma_k^2}{B},$$

$$\Rightarrow \mathbb{E}[\bar{g}_k^2] = \mu_k^2 + \frac{\sigma_k^2}{B}.$$

标量例子

$$\mu = 2, \quad \sigma^2 = 9, \quad B = 9 \Rightarrow \mathbb{E}[\bar{g}^2] = 5$$

判别预测

- 真目标: $\mu^2 = 4$
- raw 额外增加 1
- B 增大时偏差按 $1/B$ 衰减

double sample 与 U-statistic 均通过排除同一样本的自乘项实现无偏化。

等权 microbatch

$$\widehat{\mu_k^2}^U = \frac{S_{1,k}^2 - S_{2,k}}{M(M-1)} = \frac{1}{M(M-1)} \sum_{m \neq n} g_{m,k} g_{n,k}$$

- $S_{1,k} = \sum_m g_{m,k}$
- $S_{2,k} = \sum_m g_{m,k}^2$
- $M \geq 2$; 交换顺序结果不变

不等有效 token 数

$$\widehat{\mu_k^2}^{U_w} = \frac{G_{1,k}^2 - G_{2,k}}{N_1^2 - N_2}$$

- $G_{1,k} = \sum_m b_m g_{m,k}$
- $G_{2,k} = \sum_m b_m^2 g_{m,k}^2$
- $N_1 = \sum_m b_m, N_2 = \sum_m b_m^2$

一致性检查

当所有 b_m 相等时，加权式退化为等权式；分母必须严格为正。

U-statistic 的权重必须与训练损失的样本或有效 token 口径一致。

附录 | 路径积分完备性的推导

固定线性路径 $\Gamma(\alpha) = \Theta_0 + \alpha\Delta\Theta$ **与标量损失** $\mathcal{L}$ 。

$$\begin{aligned}\frac{d}{d\alpha}\mathcal{L}(\Gamma(\alpha)) &= \nabla_{\Theta}\mathcal{L}(\Gamma(\alpha))^{\top}\Delta\Theta, \\ \mathcal{L}(\Theta_1) - \mathcal{L}(\Theta_0) &= \int_0^1 \sum_k \partial_k \mathcal{L}(\Gamma(\alpha)) \Delta\theta_k d\alpha.\end{aligned}$$

定义 $C_k^{\text{path}} = -\Delta\theta_k \int_0^1 \partial_k \mathcal{L}(\Gamma(\alpha)) d\alpha$, 则

$$\sum_k C_k^{\text{path}} = \mathcal{L}(\Theta_0) - \mathcal{L}(\Theta_1)$$



附录 | 指标定义、用途与统计单位

指标	回答的问题	主要使用阶段
Bias	估计均值偏离参考多少？	Stage 2
Variance / MSE	重复波动与综合误差多大？	Stage 2
Pearson / Spearman	数值或排序是否一致？	Stage 2–3
top- <i>k</i> overlap	关键参数集合是否恢复？	Stage 2–6
Gini / entropy	重要性分布是否集中？	Stage 5–8
HHI / 有效参数数	质量由多少参数承载？	Stage 5–8
Damage AUC	剪枝全过程造成多少功能损伤？	Stage 7
配对置信区间	路线或配置差异是否稳定？	Stage 6–9

统计单位

参数坐标用于分布与排序，不充当独立重复；置信区间以 repetition、checkpoint、模型或 seed 为单位。

估计误差、排序一致性、分布集中度与功能损伤对应不同证据层级。