


参数重要性研究

后续工作流程与阶段计划



上海交通大学
2026 年 8 月 20 日


2026-08-20

参数重要性研究：后续工作流程与阶段计划



本次汇报梳理 Stage 1–9 的研究主线，图中内容都表示待完成、待检验的工作。三段主线分别是：先得到可信的数值估计，再用剪枝等干预检查功能后果，最后讨论训练过程中可能形成的结构。开场要先追问：一个重要性分数为什么还不能说明参数真的重要？若有人关心当前进展，说明这里讲的是后续计划，预期结果不会写成既成事实。

一个高分参数，真的更重要吗？



分数与功能之间还隔着一步

随机梯度噪声、数值近似和训练路径都可能改写排序。只有干预参数并观察任务损伤，才能判断它有没有功能含义。


2026-08-20

参数重要性研究：后续工作流程与阶段计划

└ 一个高分参数，真的更重要吗？

左图只是把参数按分数排序；排序高只能说明估计器给出的数值大，还不能说明删除该参数一定更伤模型。右图的任务损伤指剪枝后相对未剪枝模型的性能下降，横轴是剪掉的参数比例。

后面的九个 Stage 就是在补齐分数与功能之间的证据。右图只说明计划观察的曲线形态，目前没有实验数值，也不预设高、低重要性曲线一定按图中顺序分离。



Stage 1-9: 证据怎样一步步补齐



参数重要性研究：后续工作流程与阶段计划

2026-08-20


Stage 1-9: 证据怎样一步步补齐

九个阶段按证据依赖排列。Stage 1-3 分别处理实现、统计估计和数值积分；Stage 4-5 把方法放进 160M 与 410M 模型；Stage 6-7 比较训练路线并做剪枝干预；Stage 8-9 用消融和统一统计收束结论。图中的“放行”表示只有前一阶段达到预先定义的误差或稳定性门槛，下一阶段才开始。阶段顺序由证据依赖决定，不按模型大小机械排列。

Stage 1-9: 证据怎样一步步补齐



章节	本章要解决的问题
一	定义中的量，是否真的算对了？
二	方法放到更大模型上，还能跑通整个研究闭环吗？
三	重要性和结构能否解释训练差异，并预测剪枝损伤？
四	结论经得起消融吗，证据能否收敛复核？




实现、统计和数值误差分开核验，后面的解释才站得住。

2026-08-20

参数重要性研究：后续工作流程与阶段计划

第一章 | 先把测量做实


第一章把三类误差分开。实现误差指代码没有忠实计算公式；统计误差指有限样本带来的偏差和方差；数值误差指用有限积分节点近似连续路径时产生的截断误差。
Stage 1 先固定目标量，并用独立参考核对实现；Stage 2 比较估计器；Stage 3 再选求积规则。这样后续出现异常时，可以判断问题来自哪一层。



固定参数状态下的局部梯度空间贡献

$$\hat{C}_{k,t}^U = \eta_{g(k),t} \frac{S_{1,k,t}^2 - S_{2,k,t}}{M(M-1)}$$

- $S_{1,k,t}$: M 个 microbatch 梯度之和
- $S_{2,k,t}$: 对应梯度平方和
- 去除对角项: 目标指向总体梯度平方




这一阶段只核对实现是否忠实; 模型机理留到后面讨论。


2026-08-20

Stage 1 | 我们到底在估计什么?

这里固定参数状态 Θ_t , 只看同一时刻的梯度统计。 M 是 microbatch 数; $S_{1,k}$ 是第 k 个参数在所有 microbatch 上的梯度和, $S_{2,k}$ 是这些梯度的平方和。减去 S_2 就是在去掉每个梯度与自身相乘的对角项。
 $\eta_{g(k),t}$ 是参数所在优化器组的学习率。这个局部分数和 AdamW 的完整路径贡献不是同一个量。单步 U-statistic 允许为负; 负值来自有限样本波动, 若先截断, 再讨论无偏性就失去了意义。



Stage 1 | 用独立对照逐层核验实现



每个张量都要过独立 oracle；只看全局总和，局部错误很容易被抵消。


2026-08-20

参数重要性研究：后续工作流程与阶段计划

Stage 1 | 用独立对照逐层核验实现

oracle 是独立于被测实现的可信参考答案。这里先用很小的人工 fixture，也就是可手算的输入和梯度，在 FP64 高精度下直接枚举成对乘积；参考代码不能复用被测内核，否则两边可能共享同一个错误。通过手算后，再核对真实 Pythia-14M 张量、训练接线以及单卡和多卡结果。global batch 指一次优化更新实际看到的全部样本；多卡聚合必须与同一个 global batch 的单卡结果同尺度。相关系数只能说明走势相似，放行还要看原单位误差和归一化误差。

Stage 1 | 用独立对照逐层核验实现



每个张量都要过独立 oracle；只看全局总和，局部错误很容易被抵消。

double sample | 换成两组独立梯度


$$\widehat{\mu_k^2}^{\text{double}} = \bar{g}_k^{(A)} \bar{g}_k^{(B)},$$
$$\mathbb{E}[\widehat{\mu_k^2}^{\text{double}}] = \mu_k^2$$

- A、B 独立：乘积期望可拆开
- 代价：需要两组独立梯度

U-statistic | 在同一梯度池中删掉对角项

$$\widehat{\mu_k^2}^U = \frac{\sum_{m \neq n} g_{m,k} g_{n,k}}{M(M-1)},$$
$$= \frac{S_{1,k}^2 - S_{2,k}}{M(M-1)}$$

- S_1^2 含全部两两乘积， S_2 正好是自乘项
- 复用同一梯度池；单次估计可能为负



两种方法都把“随机梯度自乘”换成“独立梯度交叉相乘”。

2026-08-20

Stage 1 | double 与 U 怎样消掉同源偏差?

raw 使用同一批梯度的平方，因此包含 $m = n$ 的对角项；这些自乘项的期望是 $\mu_k^2 + \sigma_k^2$ ，方差由此进入目标。

double sample 把样本分成独立的 A、B 两组。独立性使乘积的期望可以拆成 $\mathbb{E}[\bar{g}^{(A)}] \mathbb{E}[\bar{g}^{(B)}] = \mu_k^2$ 。U-statistic 不另取第二组数据，而是在同一组 M 个 microbatch 梯度中删掉所有 $m = n$ 的自乘项，只平均 $m \neq n$ 的交叉项。

两者都依赖样本独立或条件独立。double 更直观但需要两组梯度；U 更节省样本，却要维护 S_1 、 S_2 ，且单次估计可能为负。下一页再看 raw 偏差为什么按 $1/B$ 衰减。

Stage 1 | double 与 U 怎样消掉同源偏差?

偏差来自对角项：同一个随机梯度与自己相乘，会额外带入方差。

double sample | 换成两组独立梯度

$$\bar{\mu}_k^{\text{double}} = \bar{g}_k^{(A)} \bar{g}_k^{(B)},$$
$$\mathbb{E}[\bar{\mu}_k^{\text{double}}] = \mu_k^2$$

- A、B 独立：乘积期望可拆开
- 代价：需要两组独立梯度

U-statistic | 在同一梯度池中删掉对角项


$$\bar{\mu}_k^U = \frac{\sum_{m \neq n} g_{m,k} g_{n,k}}{M(M-1)},$$
$$= \frac{S_{1,k}^2 - S_{2,k}}{M(M-1)}$$

- S_1^2 含全部两两乘积， S_2 正好是自乘项
- 复用同一梯度池；单次估计可能为负

```
graph LR; A[raw  
同源梯度自乘] --> B[double  
两组独立梯度交叉相乘]; B --> C[U-statistic  
删除 m = n 自乘项];
```

两种方法都把“随机梯度自乘”换成“独立梯度交叉相乘”。

- 目标: μ_k^2
- 额外项: 同源随机梯度方差
- 预测: 正偏随 batch size 按 $1/B$ 衰减




Stage 2 先把梯度噪声带来的偏差从真实信号里剥离出来。

Stage 2 | raw 为什么会系统性过估计？

设单样本梯度的均值为 μ_k 、方差为 σ_k^2 ，batch 中有 B 个独立样本。batch 平均梯度的方差是 σ_k^2/B ，因此它的平方期望比目标 μ_k^2 多出一个正项。batch 越大，这个偏差越小，但不会因为重复实验而自动消失。

图上横轴使用 $1/B$ ，理论预测 raw 应接近一条线性趋势。这里固定参数状态，只测估计量，不执行 optimizer step，以免参数更新又引入新的变化。




2026-08-20

Stage 2 | 同一预算下比较三种估计器

方法	梯度因子来源	偏差预期	主要代价
raw	同一批样本	正偏	最低
double sample	两个独立半区	无偏	两倍梯度
U-statistic	同一梯度池去对角	无偏	维护充分统计量




最终选择同时看统计效率和真实成本，形式上的无偏还不够。



最终选择同时看统计效率和真实成本，形式上的无偏还不够。

三种方法使用配对样本和相同总梯度预算。Bias 是估计均值减去参考值；Variance 衡量重复实验的波动；MSE 等于偏差平方加方差；top-k overlap 衡量两个排序最前面的参数集合有多少重合。14M 用于主比较，31M 用于确认选择能否跨规模复现。主统计单位是独立重复、checkpoint 或模型；参数坐标数量再多，也不能冒充独立样本。选定主估计器后，Stage 3 再单独看路径积分误差。



完备性检查

$$\sum_k C_{k,t} = \mathcal{L}_{\mathcal{P}}(\Theta_t) - \mathcal{L}_{\mathcal{P}}(\Theta_{t+1})$$

- 同一线性路径、同一确定性 probe
- 实际端点位移已包含优化器作用
- 不再额外乘学习率或裁剪因子

2026-08-20

Stage 3 | 沿实际更新端点定义路径贡献

Θ_t 和 Θ_{t+1} 是一次真实优化更新前后的参数， $\Delta\Theta_t$ 已经包含学习率、动量、权重衰减和裁剪等优化器作用，因此路径贡献里不能再次乘这些因子。

probe 是一批固定、独立且不参与这次更新的数据，用它测量路径上的损失梯度。完备性表示所有参数贡献求和，应恢复两个端点之间的 probe loss 差。probe 的抽样波动与求积截断误差会分开报告。

Stage 3 | 沿实际更新端点定义路径贡献

固定更新前后端点与独立 probe 损失

$$\Gamma_t(\alpha) = \Theta_t + \alpha \Delta\Theta_t$$
$$C_{k,t}^{\text{path}, \mathcal{P}} = -\Delta\Theta_{k,t} \int_0^1 \partial_{\Theta_k} \mathcal{L}_{\mathcal{P}}(\Gamma_t(\alpha)) d\alpha$$


同一条参数路径

完备性检查

$$\sum_k C_{k,t} = \mathcal{L}_{\mathcal{P}}(\Theta_t) - \mathcal{L}_{\mathcal{P}}(\Theta_{t+1})$$

- 同一线性路径、同一确定性 probe
- 实际端点位移已包含优化器作用
- 不再额外乘学习率或裁剪因子

Stage 3 | 用最少梯度节点满足精度要求




最后给出一个默认方案；若精度不够，再按预设顺序增加节点。


2026-08-20

参数重要性研究：后续工作流程与阶段计划

Stage 3 | 用最少梯度节点满足精度要求

左端点规则只计算 $\alpha = 0$ 的梯度；梯形规则计算两个端点；Simpson 使用左、中、右三个节点；Gauss-Legendre 或复合求积用更多节点作为高精度参考。节点数基本决定额外梯度计算成本。候选规则要同时通过完备性、逐参数向量误差、排序和层级聚合检查。高精度参考需要不同方法族与逐步增加节点共同收敛，避免把同一种求积规则的系统误差当成真值。






规模扩大检验的是同一套证据能否继续成立。

2026-08-20

参数重要性研究：后续工作流程与阶段计划


第二章 | 把方法放进完整研究闭环

160M 和 410M 指模型大约有 1.6 亿和 4.1 亿参数。160M 的计算成本较低，适合先检查训练、重要性记录、结构分析和剪枝能否连成一轮；410M 再用更长轨迹观察规模增大后是否仍出现相同规律。这一轮至少要回答三个问题：重要性能否稳定记录，两条路线能否公平比较，排序能否进入功能干预。任一环节失败，都先在 160M 上修正。



规模扩大检验的是同一套证据能否继续成立。

Stage 4 | 160M: 先跑通一轮完整研究



这一轮要看清

- 能否边训练边稳定记录重要性
- 这些统计能否支撑结构分析和剪枝
- 两条路线是否真的从同一起点出发

暂时不下结论

- 最终规模结论留给后续实验
- 一次剪枝曲线只作流程校验
- 估计器和求积沿用前章选择

160M 的任务是暴露流程问题，为后续放大扫清障碍。

2026-08-20


参数重要性研究：后续工作流程与阶段计划

Stage 4 | 160M: 先跑通一轮完整研究

Stage 4 关注研究闭环能不能正常工作，160M 本身不承担最终规模结论。“在线重要性”表示训练过程中按预定 checkpoint 计算并保存统计量，而不是训练结束后只看一次。闭环里最重要的对照，是统一初始化下的两条训练路线。剪枝采用临时 mask：评价时把指定参数置零或屏蔽，记录任务性能下降，评价结束后恢复原模型，不永久改写权重。



Stage 4 | 统一初始化下的两条路线




先确认对照公平；410M 阶段再检验路线差异是否稳定。

2026-08-20

参数重要性研究：后续工作流程与阶段计划

Stage 4 | 统一初始化下的两条路线

两条路线共享同一份基础初始化、模型架构和下游评价任务。左路直接在 SST-2 上做监督训练；右路先做语言模型预训练，再在同一任务上微调。这样两条路线的核心差别就是是否经历预训练。“配对比较”表示同一初始化和 seed 下的两条路线组成一对，先比较对内差值，再跨重复汇总。这里用于校准流程，正式统计放在 Stage 6。



Stage 5 | 410M: 追踪重要性如何逐步形成



参数重要性研究：后续工作流程与阶段计划

2026-08-20

Stage 5 | 410M: 追踪重要性如何逐步形成


checkpoint 是训练过程中保存的模型状态和对应训练步。Stage 5 不只读取最终 checkpoint，而是在多个时间点记录 loss、梯度范数、参数更新量和重要性，从而观察结构何时出现、何时稳定。

训练早期变化通常更快，所以观察点更密；中后期逐步拉开间隔以控制成本。signed、positive、negative 分别保留带符号贡献、正贡献和负贡献，避免绝对值掩盖方向信息。

Stage 5 | 410M: 追踪重要性如何逐步形成

训练初期多观察点，随后逐步拉开间隔

每个观察点	沿时间聚合	要回答的问题
loss, 梯度范数, 更新范数	层/模块重要性	哪些结构先分化?
raw, U, signed/positive/negative	集中度与有效参数数	重要性是否越来越集中?
参数移动量与 top-k	集合稳定性	关键参数何时稳定?



把逐参数长向量整理成可比较的动态结构。


2026-08-20


参数重要性研究：后续工作流程与阶段计划

Stage 5 | 长轨迹最后落成三类结构图

热力图回答哪些层或模块先获得较高重要性；top-k overlap 是相邻 checkpoint 的前 k 个参数集合交集占比，用来判断关键集合何时稳定。

Gini 衡量分布不均衡程度，0 表示完全均匀，越接近 1 越集中。HHI 是归一化重要性份额平方和，值越大表示质量集中在越少参数上；有效参数数常取 $1/HHI$ 。entropy 从信息熵角度衡量分散程度，方向与 HHI 相反。几项指标并列报告，是为了避免单一尺度造成误读。






结构差异先提出解释，剪枝实验再看它有没有功能后果。


2026-08-20

第三章 | 训练差异是否对应功能差异

描述性统计只能说两个模型的分布或轨迹不同；功能干预则主动删除一组参数，观察任务是否受损。第三章先用 Stage 6 建立公平的路线配对，再用 Stage 7 的定向剪枝检验差异是否有功能含义。seed 是随机初始化、数据顺序等随机过程的编号。一次终点性能差异不足以证明预训练效应，还要看收敛速度、参数结构以及多 seed 下的重复性。



Stage 6 | 两条训练路线，起点和预算都要对齐



2026-08-20

参数重要性研究：后续工作流程与阶段计划

Stage 6 | 两条训练路线，起点和预算都要对齐

SST-2 是 Stanford Sentiment Treebank 的二分类情感任务，判断一句话偏正面还是负面，数据较稳定，适合作为基础对照。MNLI 是 Multi-Genre Natural Language Inference，判断句子对属于蕴含、中立还是矛盾，规模更大、文本领域更多。RTE 是 Recognizing Textual Entailment，小数据二分类任务，用来测试样本效率。


两条训练路线在同一任务、seed、初始化和训练预算下配对。路线差异既看任务表现，也看预训练阶段形成的重要参数是否在微调中被继续使用。

Stage 6 | 两条训练路线，起点和预算都要对齐

任务角色	主要用途	压力程度
SST-2	稳定二分类对照	清晰、低噪声
MNLI	主要自然语言推理	规模与泛化
RTE	低资源压力测试	样本效率


任务表现

- 最终任务性能与置信区间
- 收敛速度与样本效率
- 多 seed 稳定性与泛化差异



参数结构

- 重要性分布与层/模块分工
- 集中度与有效参数数量
- 预训练 top-k 在微调中的复用




参数重要性研究：后续工作流程与阶段计划

2026-08-20

Stage 6 | 性能变化和参数结构要一起看

能力侧包括最终性能、达到同一性能所需的训练步数，以及多 seed 的置信区间。结构侧比较层和模块的重要性分布、集中度，以及预训练与微调前 k 个参数的重合。rank correlation 则比较完整排序的一致程度。

如果任务表现和参数结构同时稳定变化，才有理由继续讨论机制。top- k overlap 必须建立在同一参数坐标集合上；模型结构或参数命名不一致时，集合重叠没有可比性。



Stage 7 | 用同一套预算做剪枝对照

	高重要性	低重要性	随机
magnitude			
movement			
raw			
U or double			
Fisher			
SI			

每个组合都要覆盖

- 多个剪枝比例
- 全局与层内平衡
- 多随机 mask
- 语言模型与下游任务

冻结排序

临时应用 mask

评价任务损伤


预算、任务和剪枝比例全部对齐，唯一变化是排序规则。


参数重要性研究：后续工作流程与阶段计划

Stage 7 | 用同一套预算做剪枝对照

每种重要性方法都要分别剪高分参数、低分参数和随机参数，并覆盖多个剪枝比例。global pruning 在全模型统一排序；layer-balanced pruning 在每层剪相同比例，避免大层主导结果。随机 mask 需要多次抽样形成基线区间。

magnitude 按权重绝对值排序；movement 看训练中的参数移动量；Fisher 用梯度平方近似损失敏感度；SI 是 Synaptic Intelligence，用训练轨迹累计参数贡献。它们和 raw、U 或 double 在相同预算下比较。





- 满足这些条件才算通过
- 高重要性曲线显著更陡
 - 低重要性优于随机基线
 - 多比例下顺序稳定
 - AUC 差异带置信区间

解释边界


曲线不分离：仅保留描述性用途；
不宣称功能有效。

2026-08-20

参数重要性研究：后续工作流程与阶段计划

Stage 7 | 什么样的剪枝曲线才有说服力？


如果排序有功能含义，先剪高重要性参数应造成更大损伤，先剪低重要性参数应比随机更安全，而且这种次序应在多个比例上保持。曲线不分离时，只能把分数用于描述分布。
Damage AUC 是任务损伤曲线在剪枝比例轴下的面积，把多个比例压成一个整体指标；面积越大，表示全过程损伤越重。置信区间来自多 seed 和多随机 mask，而不是把参数坐标当作独立重复。



- 满足这些条件才算通过
- 高重要性曲线显著更陡
 - 低重要性优于随机基线
 - 多比例下顺序稳定
 - AUC 差异带置信区间

解释边界

曲线不分离：仅保留描述性用途；
不宣称功能有效。




跨因素仍稳定的结果，才值得写进主结论。

2026-08-20


参数重要性研究：后续工作流程与阶段计划

第四章 | 先划边界，再整理证据

消融实验是一次只改变一个条件，检查主结论是否随该条件改变。Stage 8 用它判断结果是普遍稳定、只在部分设置下稳定，还是会发生方向反转。Stage 9 的结论—证据对照，会把论文中的一句结论指向具体表格、图、统计量和对应阶段。一项结论只有经受敏感性检验，并且能够被另一位研究者沿证据路径复核，才算收束。



跨因素仍稳定的结果，才值得写进主结论。



消融要找出结论成立所需的条件，实验数量本身没有意义。

这样做能看清什么

- 父子实验共享其余条件
- 效应可归因于注册因素
- 避免组合变化掩盖根因


矩阵先定，结果后看

所有组合按同一规则汇总；没有运行过的组合不作外推。


2026-08-20

Stage 8 | 一次只动一个条件

每个子实验相对基准只改一个条件。batch size 改变单次估计使用的数据量；microbatch 数影响 U-statistic 的成对结构；积分节点控制求积精度；正负贡献和归一化方式改变分数的汇总口径。模型规模、seed 和数据规模用于检查结论能否跨设置复现。checkpoint 频率也会纳入分析，只是没有画进主矩阵。结果不能停在显著性列表上，还要写清推荐设置和外推边界。



Stage 8 | 敏感性结果最终要写成适用边界



多项因素下都稳定
可作为默认结论

只对部分条件稳定
写明使用条件

关键结论发生反转
缩小适用范围

最终要交代
推荐设置、适用范围、局限，以及尚未覆盖的组合。


2026-08-20

参数重要性研究：后续工作流程与阶段计划


Stage 8 | 敏感性结果最终要写成适用边界

左侧是 forest plot 的示意：每个点表示相对基准的效应估计，横线表示不确定性区间，竖直的 0 表示与基准无差异。区间跨过 0 时，现有重复不足以确认效应方向。

多项因素下都稳定，可以写成默认结论；只在部分条件下稳定，就要附带使用条件；关键结论反转，则缩小适用范围。没有覆盖到的模型、任务或数据规模必须写进外推边界。



Stage 9 | 把零散结果整理成一套证据



所有图表都从同一份结果表生成，研究者负责解释。


2026-08-20

参数重要性研究：后续工作流程与阶段计划


Stage 9 | 把零散结果整理成一套证据

Stage 9 把训练记录、重要性统计和剪枝评价整理到同一结果表，再用固定脚本生成图表。Bias、Variance 和 MSE 评价估计误差；Pearson 比较数值线性关系；Spearman 比较排序；Gini、entropy 和 HHI 描述集中度；Damage AUC 汇总功能损伤。

同一指标在所有阶段使用相同定义和统计单位。遇到常量向量、零总质量等不可定义情形，要报告原因，不能加一个 epsilon 凑出看似正常的数值。



Stage 9 | 每句话都要找到证据出处



结论怎么写
只写证据能够支持的范围：支持、不支持，或目前证据不足。判据不随结果方向改变。


Stage 9 结束时，论文里的每项结论都能沿表、图和统计定义回溯。

2026-08-20


参数重要性研究：后续工作流程与阶段计划

Stage 9 | 每句话都要找到证据出处

左侧三条结论是论文可能采用的陈述，右侧列出它们至少需要哪些阶段共同支撑。例如 raw 正偏不能只靠一条理论公式，还要有 oracle 校准和配对实验；训练路线形成不同功能结构，则需要轨迹、路线比较、剪枝和消融共同支持。
证据索引要能从一句话回到表、图、统计定义和原始结果。若证据不支持原假设，就把结论写成不支持或证据不足；这不等于实验执行失败。



关键路径 | 什么时候可以进入下一阶段?




2026-08-20

参数重要性研究：后续工作流程与阶段计划

关键路径 | 什么时候可以进入下一阶段?

这是一条带 Gate 的关键路径。S2 结束时要选出主估计器；S3 结束时要选出默认求积规则；S4 要证明 160M 闭环能完整运行；S7 要判断排序是否具有功能证据。
Gate 不是进度检查，而是预先定义的科学门槛。某一处未通过，只回到对应环节补参考、节点或重复；无关阶段不必整体重做，也不能因为日历到期就直接放大。



一路上需要做出的五个选择

参数重要性研究：后续工作流程与阶段计划

2026-08-20

一路上需要做出的五个选择

五个选择分别决定使用哪种估计器、用多少积分节点、是否扩大模型、能否宣称功能含义，以及最终结论写到多强。每项选择都有输入证据、一个明确输出和未通过时的回退方向。这些判断规则要在看到正式结果前冻结。这样资源安排可以围绕尚未通过的 Gate 展开，也能避免看完结果后再修改成功标准。



证据达到门槛就继续；达不到，就回到对应环节补足。

一路上需要做出的五个选择			
序号	决策	主要证据	输出
1	主估计器	Bias / MSE / 程序 / 成本	U 或 double
2	默认求积	完备性 / 向量误差 / 节点成本	左端点、梯形或更高阶
3	是否规模化	160MA 完整闭环	进入 410MA 验证
4	是否具备功能含义	离/低/随机/树枝损伤	功能有效或仅描述性
5	结论强度	理论数消耗与附 seed 稳定性	默认、条件化或收敛

1 | 估计

2 | 求积

3 | 放大


4 | 功能

5 | 结论


证据达到门槛就继续；达不到，就回到对应环节补足。

最后记住三件事


1



2



3




整项研究要把定义、估计、轨迹、干预和稳健性接成一条可核验的链。

参数重要性研究：后续工作流程与阶段计划

2026-08-20

最后记住三件事

第一件事是把实现、统计和数值三类误差分开，否则一个漂亮分数可能只是计算误差。第二件事是保留训练轨迹，因为终点模型无法告诉我们结构何时形成。第三件事是用定向剪枝限定解释强度，只有干预造成可重复的损伤差异，重要性才具有功能含义。这三件事也对应论文实验部分的自然结构。下一页列出方法和模型选择的主要学术来源。



 [Parameter Importance Project.](#)
参数重要性研究实验计划与统一数学规格.
Internal research documents, 2026.

 [W. Hoeffding.](#)
A Class of Statistics with Asymptotically Normal Distribution.
The Annals of Mathematical Statistics, 19(3):293–325, 1948.

 [M. Sundararajan, A. Taly, and Q. Yan.](#)
Axiomatic Attribution for Deep Networks.
ICML, PMLR 70:3319–3328, 2017.

 [S. Biderman et al.](#)
Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling.
ICML, PMLR 202:2397–2430, 2023.


 [P. Molchanov et al.](#)
Importance Estimation for Neural Network Pruning.
CVPR, 11264–11272, 2019.

2026-08-20

参考文献

Hoeffding 1948 是 U-statistic 的经典来源, 说明如何用样本间核函数构造无偏估计。Integrated Gradients 提供路径积分与完备性公理的相关思想。Pythia 提供跨训练过程和模型规模的开放 checkpoint, 适合研究形成轨迹。Molchanov 等工作代表基于梯度或 Taylor 近似的剪枝重要性。内部数学规格决定本项目的符号、权重和解释边界；外部文献提供统计与归因背景。主讲部分用下一页的开放问题收住。

参考文献	
	Parameter Importance Project. 参数重要性研究实验计划与统一数学规格. <i>Internal research documents</i> , 2026.
	W. Hoeffding. A Class of Statistics with Asymptotically Normal Distribution. <i>The Annals of Mathematical Statistics</i> , 19(3):293–325, 1948.
	M. Sundararajan, A. Taly, and Q. Yan. Axiomatic Attribution for Deep Networks. <i>ICML</i> , PMLR 70:3319–3328, 2017.
	S. Biderman et al. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. <i>ICML</i> , PMLR 202:2397–2430, 2023.
	P. Molchanov et al. Importance Estimation for Neural Network Pruning. <i>CVPR</i> , 11264–11272, 2019.



感谢聆听·Q&A

2026-08-20

参数重要性研究：后续工作流程与阶段计划

讨论 | 这项研究最后想回答什么？

这里回到开场的问题。梯度和参数更新是优化过程，重要性轨迹是我们尝试提取的中间结构，剪枝损伤和下游性能则对应模型功能。研究目标是检验这三层之间是否存在稳定、可复核的联系。进入提问后，可根据问题跳到备份页：raw 偏差看推导，U-statistic 看等权与加权公式，路径积分看完备性，指标选择看最后一页词典。

讨论 | 这项研究最后想回答什么？

参数重要性的形成过程，
能否成为连接优化动态与泛化能力的中间表征？

感谢聆听·Q&A



什么时候用

遇到公式、权重、完备性或指标口径问题时，再跳到对应页面。

2026-08-20

参数重要性研究：后续工作流程与阶段计划

Backup Slides

备份部分不计入主讲时间。第一页推导 raw 的方差正偏；第二页给出等权和按有效 token 加权的 U-statistic；第三页从链式法则推导路径完备性；第四页说明每个统计指标回答什么问题。提问时不必按顺序播放，直接跳到对应页面即可。

Backup Slides

备份材料 | 常见追问

什么时候用

遇到公式、权重、完备性或指标口径问题时，再跳到对应页面。

标量例子

$\mu = 2, \quad \sigma^2 = 9, \quad B = 9 \Rightarrow \mathbb{E}[\bar{g}^2] = 5$

判别预测

- 真目标: $\mu^2 = 4$
- raw 额外增加 1
- B 增大时偏差按 $1/B$ 衰减

double sample 和 U-statistic 都是在去掉同源对角项。

2026-08-20

$\bar{g}_k$ 是 B 个样本梯度的平均。它的期望是总体均值 μ_k ，方差是 σ_k^2/B 。利用 $\mathbb{E}[X^2] = \text{Var}(X) + \mathbb{E}[X]^2$ ，就得到 raw 比目标 μ_k^2 多出 σ_k^2/B 。

例子中目标是 4，raw 的期望是 5，多出的 1 正是方差项。若样本相关， $\text{Var}(\bar{g})$ 还包含协方差，不能继续使用独立样本下的简式。

备份 | raw 正偏从哪里来？

为什么同一个 minibatch 的平均梯度平方不是 μ_k^2 ？

$$\bar{g}_k = \frac{1}{B} \sum_{i=1}^B g_k(x_i), \quad \mathbb{E}[\bar{g}_k] = \mu_k,$$
$$\mathbb{E}[\bar{g}_k^2] = \text{Var}(\bar{g}_k) + \mathbb{E}[\bar{g}_k]^2, \quad \text{Var}(\bar{g}_k) = \frac{\sigma_k^2}{B},$$
$$\Rightarrow \mathbb{E}[\bar{g}_k^2] = \mu_k^2 + \frac{\sigma_k^2}{B}.$$

标量例子	判别预测
$\mu = 2, \quad \sigma^2 = 9, \quad B = 9 \Rightarrow \mathbb{E}[\bar{g}^2] = 5$	• 真目标: $\mu^2 = 4$ • raw 额外增加 1 • B 增大时偏差按 $1/B$ 衰减

double sample 和 U-statistic 都是在去掉同源对角项。

- $S_{1,k} = \sum_m g_{m,k}$
- $S_{2,k} = \sum_m g_{m,k}^2$
- $M \geq 2$; 交换顺序结果不变
- $G_{1,k} = \sum_m b_m g_{m,k}$
- $G_{2,k} = \sum_m b_m^2 g_{m,k}^2$
- $N_1 = \sum_m b_m, \quad N_2 = \sum_m b_m^2$

一致性检查

当所有 b_m 相等时，加权式退化为等权式；分母必须严格为正。

权重应与训练损失的统计单位一致；microbatch 不能默认等权。

等权式用 $M(M-1)$ 个有序交叉对， $S_1^2 - S_2$ 是它的快速计算形式。若各 microbatch 的有效 token 数 b_m 不同，梯度在训练损失中的权重也不同，因此要改用 G_1 、 G_2 、 N_1 、 N_2 的加权式。分母 $N_1^2 - N_2$ 是所有不同 microbatch 权重乘积之和，必须严格为正。所有 b_m 相等时，加权式应退化为等权式，这是重要的一致性检查。

备份 等权与加权 U-statistic	
等权 microbatch	不等有效 token 数
$\overline{\mu_k^U} = \frac{S_{1,k}^2 - S_{2,k}}{M(M-1)} = \frac{1}{M(M-1)} \sum_{m \neq n} g_{m,k} g_{n,k}$	$\overline{\mu_k^{tk}} = \frac{G_{1,k}^2 - G_{2,k}}{N_1^2 - N_2}$
• $S_{1,k} = \sum_m g_{m,k}$ • $S_{2,k} = \sum_m g_{m,k}^2$ • $M \geq 2$; 交换顺序结果不变	• $G_{1,k} = \sum_m b_m g_{m,k}$ • $G_{2,k} = \sum_m b_m^2 g_{m,k}^2$ • $N_1 = \sum_m b_m, \quad N_2 = \sum_m b_m^2$
一致性检查	
当所有 b_m 相等时，加权式退化为等权式；分母必须严格为正。	
权重应与训练损失的统计单位一致；microbatch 不能默认等权。	

备份 | 路径积分的完备性从哪里来？



参数重要性研究：后续工作流程与阶段计划

备份 | 路径积分的完备性从哪里来？

在线性路径上，损失对路径参数 α 的导数等于梯度与端点位移的内积。对 α 从 0 积到 1，根据微积分基本定理得到端点 loss 差；再按参数坐标拆开内积，就得到逐参数贡献。

因此完备性是定义本身的恒等式。数值结果若偏离，应依次检查积分节点是否足够、模型状态和 probe 是否固定，以及浮点精度是否造成累计误差。

备份 | 路径积分的完备性从哪里来？

固定线性路径 $\Gamma(\alpha) = \theta_0 + \alpha \Delta \theta$ 与标量损失 $\mathcal{L}$ 。

$$\frac{d}{d\alpha} \mathcal{L}(\Gamma(\alpha)) = \nabla_{\theta} \mathcal{L}(\Gamma(\alpha))^T \Delta \theta,$$
$$\mathcal{L}(\theta_1) - \mathcal{L}(\theta_0) = \int_0^1 \sum_{\alpha} \partial_{\alpha} \mathcal{L}(\Gamma(\alpha)) \Delta \theta_{\alpha} d\alpha.$$

定义 $C_{\alpha}^{\text{path}} = -\Delta \theta_{\alpha} \int_0^1 \partial_{\alpha} \mathcal{L}(\Gamma(\alpha)) d\alpha$, 则

$$\sum_{\alpha} C_{\alpha}^{\text{path}} = \mathcal{L}(\theta_1) - \mathcal{L}(\theta_0)$$

固定端点与路径 → 沿路径积分梯度 → 逐参数贡献求和 → 得到端点 loss 差

备份 | 这些指标各自回答什么？

参数重要性研究：后续工作流程与阶段计划

2026-08-20

备份 | 这些指标各自回答什么？

Bias、Variance、MSE 回答估计值是否准确；Pearson 比较数值线性一致性，Spearman 比较排序一致性；top-k overlap 只看最重要参数集合。Gini、entropy、HHI 和有效参数数描述重要性集中程度。Damage AUC 汇总剪枝全过程的功能损伤。

置信区间以 repetition、checkpoint、模型或 seed 为单位，参数坐标不算独立重复。常量向量会让相关系数不可定义，零总质量会让集中度归一化失效，这些情况应报告 NA 及原因。

备份 | 这些指标各自回答什么？

指标	回答的问题	主要使用阶段
Bias	估计均值偏差参考多少？	Stage 2
Variance / MSE	重复波动与拟合误差多大？	Stage 2
Pearson / Spearman	数值或排序是否一致？	Stage 2-3
top-k overlap	关键参数集合是否重叠？	Stage 2-6
Gini / entropy	重要性分布是否集中？	Stage 5-8
HHI / 有效参数数	质量由多少参数承载？	Stage 5-8
Damage AUC	剪枝全过程造成多少功能损伤？	Stage 7
配对置信区间	路线或配置差异是否稳定？	Stage 6-9

统计单位
参数坐标用于分布与排序，不充当独立重复；置信区间以 repetition、checkpoint、模型或 seed 为单位。
相关性、集中度和功能损伤各答各的问题，不能互相替代。

统计单位

参数坐标用于分布与排序，不充当独立重复；置信区间以 repetition、checkpoint、模型或 seed 为单位。

相关性、集中度和功能损伤各答各的问题，不能互相替代。