

Stage 2 估计器比较与后续实验选择报告

基于真实 Pythia-14M / Pythia-31M 的 direct run

Parameter Importance Project

2026 年 8 月 28 日

一句话结论。 若后续实验必须采用一个统一配置，当前数据支持以 $U-32$ 、 $B = 32$ 作为默认主估计器；初始化阶段优先检查 U-8，中后期保留 U-16，并始终保留 Raw 作为阶段敏感性对照。Double 与 U-2 在本实现中数值等价，不需要同时作为独立候选。

目录

1 技术摘要	2
2 数据范围与分析口径	2
3 估计器比较结果	4
4 样本预算、时间与显存	9
5 后续实验的估计器选择	13
6 数据边界与使用说明	14
7 可复现入口与数据身份	14
8 结论	15

1 技术摘要


本报告分析了 Stage 2 direct real-Pythia 数据中的全部 168 个候选汇总：2 个模型规模、3 个训练阶段、4 个样本预算 B 和 7 种估计器。除 `pythia-31m-deduped:mid_late`, $B=64$ 的交付汇总使用续跑段 $n = 18$ 外，其余 `cell-batch` 汇总均使用 $n = 64$ 次成功重复。所有主要结论均来自真实 Pythia 结果，不以合成数据替代。

数据给出四个直接可用于后续实验设计的结论：

1. 不存在跨模型、跨阶段的单一逐 `cell` 最优估计器。六个 `cell` 的最低 MSE 分别由 `Raw`、`Double`、`U-8`、`U-16` 和 `U-32` 获得。
2. 若追求跨场景稳定性，**U-32** 最适合作为统一默认。在 24 个 `cell`× B 场景中，U-32 的平均 MSE 排名为 3.08，优于 U-16 的 3.33 和 U-8 的 3.42；其跨场景几何平均 MSE 相对 `Raw` 低 7.59%。
3. **Raw** 是高异质性估计器。它在 24 个场景中 8 次排名第一，但中位排名为第 7；因此适合作为简单基线和阶段敏感性对照，不适合作为不区分阶段的唯一默认。
4. $B = 32$ 是当前数据下的首选样本预算。在 42 个 `cell`×method 比较中， $B = 32$ 有 27 次取得该组合的最低 MSE；中位壁钟时间为 7.71 秒，相比 $B = 256$ 的 12.65 秒减少 39%。

逐模型与训练阶段的最低 MSE 配置

在每个真实 Pythia cell 的 28 个 method× B 候选中选择最低观测 MSE



来源：Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

图 1：六个真实 Pythia cell 的最低观测 MSE 配置。结果显示最优方法依赖模型规模与训练阶段。

2 数据范围与分析口径


2.1 实验矩阵

本次分析的基本单位是一个候选汇总 (model, stage, B , method)。实验范围如下：

维度	取值
模型	Pythia-14M (14,067,712 个坐标); Pythia-31M-deduped (30,494,720 个坐标)
阶段	initialization、early、mid_late
样本预算	$B \in \{32, 64, 128, 256\}$
估计器	Raw、Double、U-2、U-4、U-8、U-16、U-32
重复	通常每个 $\text{cell} \times B$ 为 64 次; 一个续跑汇总为 18 次
候选数	$2 \times 3 \times 4 \times 7 = 168$

成功重复次数覆盖矩阵

每格同时覆盖 7 种估计器; 计划值为 64 次重复



来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

图 2: 进入精度比较的成功重复次数。每个格子的重复样本同时支持 7 种配对估计器。

Pythia-31M 中后期 $B = 64$ 的原始运行在一个 CUDA 错误后由续跑段完成。原始 JSONL 中保留了前段成功记录, 但现有 Stage 2 交付的 7 个候选行均绑定续跑段的 batch summary, 因此图表使用该已发布汇总中的 $n = 18$ 数值, 不对未保存完整坐标向量的两段均值进行事后近似合并。

2.2 估计器定义

设一个固定参数状态下的梯度统计单元为 g_i 。Raw 估计器直接平方同一样本池的平均梯度:

$$\hat{I}_{\text{Raw}} = \left(\frac{1}{B} \sum_{i=1}^B g_i \right)^2. \quad (1)$$

Double 将样本划分为两个互不重叠的半池:

$$\hat{I}_{\text{Double}} = \bar{g}_A \bar{g}_B. \quad (2)$$

U- M 先形成 M 个组梯度 $\tilde{g}_m$ ，再删除自乘项：

$$\hat{I}_{U,M} = \frac{\left(\sum_{m=1}^M \tilde{g}_m\right)^2 - \sum_{m=1}^M \tilde{g}_m^2}{M(M-1)}. \quad (3)$$

当 $M = 2$ 时，U-2 与 Double 是同一代数构造。本次 168 行结果中，两者的 MSE、MAE 和 Pearson 最大绝对差分别为 2.58×10^{-26} 、0 和 1.11×10^{-16} ，属于浮点舍入量级。

2.3 精度、排序与稳定性指标

对于候选均值向量 $\hat{\mathbf{I}}$ 与参考向量 $\mathbf{I}^*$ ，报告使用：

$$\text{MSE} = \frac{1}{d} \sum_{k=1}^d (\hat{I}_k - I_k^*)^2, \quad (4)$$

$$\text{MAE} = \frac{1}{d} \sum_{k=1}^d |\hat{I}_k - I_k^*|, \quad (5)$$

$$\rho = \text{Pearson}(\hat{\mathbf{I}}, \mathbf{I}^*). \quad (6)$$

同时从 batch summary 中提取 signed bias mean，以及按坐标数加权的 between-repetition variance mean，用于描述偏差与重复稳定性。MSE/MAE 越低越好；Pearson 越接近 1，参数相对排序保持度越高。


3 估计器比较结果

3.1 跨场景平均表现：U-32 最稳健，Raw 最分化

图 3 将每个 $\text{cell} \times B$ 内的 7 种方法按 MSE 排序，再对 24 个场景取平均。排名指标避免不同模型和阶段的 MSE 绝对尺度直接相加。U-32 的平均排名最低；U-16 与 U-8 紧随其后。三者的跨场景几何平均 MSE 仅相差 0.017% 以内，因此 U-32 的优势主要是跨场景排序更稳定，而不是数量级差异。

估计器在 24 个 cell×B 场景中的平均 MSE 排名

横轴越小越好；右侧数字为并列第一的场景数



来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z


图 3: 24 个 cell×B 场景的平均 MSE 排名。菱形为中位排名；Double 与 U-2 的排名完全一致。

方法	平均排名	第一名次数	几何平均 MSE/Raw	Pearson 中位数
U-32	3.08	4	0.9241	0.9252
U-16	3.33	3	0.9242	0.9252
U-8	3.42	5	0.9243	0.9250
U-4	4.25	1	0.9252	0.9238
Double	4.46	0	0.9269	0.9237
U-2	4.46	0	0.9269	0.9237
Raw	5.00	8	1.0000	0.9182

Raw 的 8 次第一名与中位第 7 名同时存在，说明它不是稳定地“第二梯队”，而是随 cell 改变在最好与最差之间切换。这一模式决定了后续实验应保留 Raw 作为对照，却不应仅凭少数逐 cell 胜出结果将其设为统一默认。

相对 Raw 的 MSE 分布

每个点对应一个 cell×B 场景；0 表示与 Raw 相同，负值表示更低 MSE



来源：Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

图 4: 各方法相对同一 cell×B 下 Raw 的 MSE。U 系列和 Double 的中位数均低于 Raw，但分布包含场景反转。

3.2 模型与阶段依赖

Pythia-14M 与 Pythia-31M 的完整曲线分别见图 5 和图 6。U 系列曲线在多数位置紧密重合，Raw 则经常与无偏化方法分离。分阶段汇总显示：

- **初始化：**U-8 的平均排名最好（3.25），但 Raw 在两个模型的 8 个 batch 场景中有 4 次第一；应采用 U-8 主分析加 Raw 敏感性对照。
- **早期：**U-32 平均排名 2.25，Raw 在 8 个场景中平均排名第 7；这是 U-32 最明确的适用阶段。
- **中后期：**U-16 与 U-32 平均排名同为 3.625；Raw 在两个模型上呈现不同方向，因此建议 U-16/U-32 主分析并保留 Raw。




图 5: Pythia-14M 中不同估计器的 MSE-B 曲线。Double 与 U-2 曲线重合。





图 6: Pythia-31M 中不同估计器的 MSE-B 曲线。中后期 $B = 64$ 点使用已交付的 $n = 18$ 续跑汇总。

3.3 排序保持度与偏差-方差位置

Pearson 指标的跨方法差异小于 MSE 排名差异。U-32 的 Pearson 中位数为 0.92523，Raw 为 0.91821。换言之，无偏化方法对全坐标误差的改善更明显，而全局排序保持度的改善较温和。

各估计器的 Pearson 排序保持度

跨 24 个 cell×B 场景；纵轴聚焦观测区间，箱体表示中位数与四分位范围



来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

图 7: 24 个场景中 Pearson 相关系数的分布。纵轴聚焦观测区间。

U-32 相对 Raw 的 signed bias 绝对值中位数降低 28.17%，逐坐标跨重复方差中位数降低 2.56%。U-8、U-16 与 U-32 聚集在相近区域，再次说明 U 系列内部差异较小；最重要的结构性差异是 Raw 与无偏化方法之间的分离。

估计器的偏差—重复方差位置

每个点为 24 个 cell×B 场景的中位数；左下方向同时降低绝对偏差与跨重复方差




图 8: 偏差-重复方差位置。Double 与 U-2 完全重合；左下方表示两项指标同时较低。


4 样本预算、时间与显存

4.1 $B = 32$ 在当前比较中最常取得最低 MSE

对每个 cell×method 单独选择最低 MSE 的 B ， $B = 32$ 在 42 个比较中胜出 27 次 (64.3%)。 $B = 128$ 仅胜出 2 次。该结果意味着当前任务中更大样本预算并未单调改善相对参考向量的误差，因此后续实验不应默认把更大 B 当作更高精度配置。

每个 cell×估计器的最低 MSE 所对应样本预算

共 42 个 cell×method 比较；柱高为该 B 成为最低 MSE 的次数



来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

图 9: 42 个 cell×method 比较中，各样本预算取得最低 MSE 的次数。

4.2 时间随 B 上升，显存主要由模型规模决定

每次 repetition 同时计算 Raw、Double 与全部 U-M，所以 profiler 不能拆出单个估计器的独立耗时。它能回答的是：在同一套估计器输出下，样本预算 B 的总体成本如何变化。六个 cell 的中位壁钟时间从 $B = 32$ 的 7.71 秒增长到 $B = 256$ 的 12.65 秒，即 1.64 倍。峰值显存则在同一模型内基本稳定，Pythia-14M 约 11.9–12.1 GiB，Pythia-31M 约 25.7–26.1 GiB。

样本预算与壁钟时间

每个 B 的一次 repetition 同时计算 Raw、Double 与全部 U-M；时间主要随梯度样本预算增长




图 10: 样本预算与每次重复壁钟时间。Pythia-14M early 的非单调点说明共享运行环境中存在计时波动。

样本预算与峰值显存

峰值为每个 cell×B 的最大观测值；按模型分面并聚焦各自纵轴范围




图 11: 样本预算与峰值显存。纵轴按模型分别聚焦局部范围。

4.3 精度-时间联合选择

图 12 在每个 cell、每个 B 中只保留最低 MSE 方法。五个 cell 的全局最低 MSE 位于 $B = 32$ ；Pythia-14M early 的例外是 Double、 $B = 64$ 。因此， $B = 32$ 是统一运行的默认点，而 Double、 $B = 64$ 是一个明确但窄的 early-stage 特化点。




图 12: 逐 cell 的精度-时间散点。每个 B 标注该 cell $\times B$ 中 MSE 最低的方法。

5 后续实验的估计器选择

5.1 默认与阶段化建议

使用情境	主估计器	样本预算	配套对照与理由
跨模型、跨阶段 统一默认	U-32	$B = 32$	平均 MSE 排名最好；相对 Raw 的几何平均 MSE 低 7.59%；成本最低档
初始化阶段	U-8	$B = 32$	同时保留 Raw；U-8 跨两个模型的平均排名最好，Raw 在部分初始化 cell 直接胜出
训练早期	U-32	$B = 32$	Pythia-14M 若追求该 cell 最低观测 MSE，可使用 Double、 $B = 64$
中后期	U-16 或 U-32	$B = 32$	保留 Raw；U-16/U-32 跨场景稳健，Raw 在 Pythia-31M 中后期胜出
最小双方法方案	U-32	$B = 32$	配 Raw；一条稳健主线加一条高异质性基线
代数核验	Double 或 U-2	任一	两者等价，仅保留一个输出；另一项用于实现不变量检查

若后续实验允许记录三种方法，推荐 Raw+U-16+ U-32；初始化专项可将 U-16 替换为 U-8。U-4 在 24 个场景中仅 1 次排名第一，且平均排名弱于更高 M 的 U 估计器；除消融研究外，不建议将其列为主结果。

5.2 逐 cell 的观测精度

模型-阶段	方法	B	MSE	MAE	Pearson
14M-初始化	Raw	32	1.40×10^{-12}	5.88×10^{-8}	0.9870
14M-早期	Double	64	3.61×10^{-12}	1.30×10^{-7}	0.9445
14M-中后期	U-16	32	9.19×10^{-11}	1.85×10^{-7}	0.8232
31M-初始化	U-8	32	3.99×10^{-13}	4.84×10^{-8}	0.9930
31M-早期	U-32	32	1.06×10^{-13}	3.20×10^{-8}	0.8282
31M-中后期	Raw	32	1.93×10^{-10}	2.63×10^{-7}	0.8982

以上六个选中配置的 MSE 范围为 1.06×10^{-13} 至 1.93×10^{-10} ，MAE 为 3.20×10^{-8} 至 2.63×10^{-7} ，Pearson 为 0.823 至 0.993。不同 cell 的目标向量尺度不同，因此这些绝对误差主要用于同一 cell 内方法比较，不宜直接用来排列训练阶段本身的“难度”。

6 数据边界与使用说明

本报告的目的，是把已得到的数据转化为后续实验可执行的估计器选择。使用这些结论时需要保留以下数据事实：

- 结果覆盖两个小型 Pythia 规模和三个训练阶段；跨更大模型时，应首先复用 $U=32$ 、 $B=32$ 默认，并同时保留 Raw 对照。
- profiler 在一次 repetition 中联合计算全部估计器，不能据此声称某个估计器单独快多少；现有时间结论针对 B 的总体运行成本。
- Pythia-31M 中后期 $B=64$ 的候选精度来自 $n=18$ 的续跑汇总；其余汇总为 $n=64$ 。
- Double 与 U-2 不构成两个独立证据流；它们的数值一致性应被解释为实现不变量，而不是两次独立复现。

7 可复现入口与数据身份

所有图表和派生 CSV 均由同目录下的 `analysis.py` 生成。运行入口：

```
python analysis.py --input-root <pythia-grid-20260826T145530Z> \
--output-root <presentation/Stage 2>
```

关键身份如下：

字段	值
Run ID	pythia-grid-20260826T145530Z
Main sweep artifact	ff84d8032113da703753282ba1ebdfe9b08bfbb7f36818988870d252ed2b4d4e
Profiler artifact	f33160b33c7a2b3b5afd275243d05e5fb4a48b24d42c3b5ac58e1d14e1174879
Delivery hash	730bf865d2b4eaf60f32cce309560db954a54bbfff4a1cbb69d79383b8c6d78f
Analysis payload	44da7d9fecde8847bc88661db2fd9310928e46ba4d7a851b4ff115a43b567325

机器可读结果随报告一并交付：

- 汇总、来源哈希与逐 cell 推荐： `data/analysis-summary.json`；
- 完整派生表： `data/*.csv`。

8 结论

Stage 2 数据已经足以给后续实验指定一个明确而不过度简化的选择策略：

1. 统一默认使用 **U-32**、 $B = 32$ ；
2. 初始化阶段检查 U-8+Raw；
3. 早期阶段优先 U-32，Pythia-14M 特化点为 Double、 $B = 64$ ；
4. 中后期使用 U-16/U-32，并保留 Raw；
5. 不同时保留 Double 与 U-2 作为独立实验分支。

这套选择同时利用了逐 cell 最优结果、跨场景平均排名、偏差-方差位置以及样本预算的时间成本。最核心的发现不是“某个估计器永远获胜”，而是：**U-32 提供最稳健的跨场景默认，Raw 提供不可替代的阶段敏感性对照， $B = 32$ 提供当前数据下最好的精度-成本起点。**

参考文献

- [1] W. Hoeffding. A Class of Statistics with Asymptotically Normal Distribution. *The Annals of Mathematical Statistics*, 19(3), 1948.
- [2] S. Biderman et al. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. *Proceedings of ICML*, 2023.
- [3] P. Molchanov et al. Importance Estimation for Neural Network Pruning. *Proceedings of CVPR*, 2019.
- [4] Parameter Importance Project. Stage 2 direct real-Pythia run: pythia-grid-20260826T145530Z. Internal experiment artifact, 2026.