

Stage 2: 估计器怎么选?

从 168 个真实 Pythia 候选到可执行的后续实验配置

2 个模型 $\times$ 3 个阶段

4 个样本预算 $\times$ 7 种估计器

默认答案

U-32, $B = 32$

结论先行：统一默认 + 阶段化例外

统一默认
U-32

样本预算
 $B = 32$

后续实验的最小决策规则

- **初始化**: U-8, 同时保留 Raw;
- **训练早期**: U-32; Pythia-14M 可特化为 Double、 $B = 64$;
- **中后期**: U-16 或 U-32, 同时保留 Raw;
- Double 与 U-2 等价, 只保留一个输出。

这是一套**依据当前数据内容可执行**的估计器选择策略。

来源: Stage 2 direct real-Pythia run, run id: pythia-grid-20260826T145530Z

我们比较了什么？

完整实验矩阵

14M	31M	×	初始	早期	中后期	×
32	64	128	256	Raw / Double / U-2 / 4 / 8 / 16 / 32		

$$2 \times 3 \times 4 \times 7 = 168$$

个候选汇总

来源：除 31M 中后期、 $B = 64$ 的交付汇总为 $n = 18$ 外，其余均为 $n = 64$ 。

比较指标

- MSE：主排序指标
- MAE：绝对误差
- Pearson：形状保持
- signed bias：系统偏差
- between-repetition variance：重复稳定性
- 壁钟时间 / 峰值显存

估计器与读图口径

三类估计器

$$\hat{I}_{\text{Raw}} = \left(\frac{1}{B} \sum_{i=1}^B g_i \right)^2$$

$$\hat{I}_{\text{Double}} = \bar{g}_A \bar{g}_B$$

$$\hat{I}_{U,M} = \frac{\left(\sum_{m=1}^M \bar{g}_m \right)^2 - \sum_{m=1}^M \bar{g}_m^2}{M(M-1)}$$

如何判断“更好”


- MSE / MAE: **越低越好**
- Pearson: **越接近 1 越好**
- 排名: 在同一 cell、同一 B 内比较
- 成本: profiler 同时算全部方法, **不能拆分单方法耗时**

关键不变量: 当 $M = 2$ 时, U-2 与 Double 代数等价。

数据覆盖完整，但有一个交付边界

成功重复次数覆盖矩阵

每格同时覆盖 7 种估计器，计划值为 64 次重复



来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

23 个 cell-batch 汇总为 $n = 64$; **31M 中后期、 $B = 64$ 为 $n = 18$**

来源: 图中每格同时支持 7 种估计器; 覆盖共 168 个候选。

六个 cell, 出现五种最低 MSE 配置

逐模型与训练阶段的最低 MSE 配置

在每个真实 Pythia cell 的 28 个 method×B 候选中选择最低观测 MSE

	初始化	早期	中后期
Pythia-14M	Raw B=32 MSE=1.40e-12	Double B=64 MSE=3.61e-12	U-16 B=32 MSE=9.19e-11
Pythia-31M	U-8 B=32 MSE=3.99e-13	U-32 B=32 MSE=1.06e-13	Raw B=32 MSE=1.93e-10

来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

14M: Raw → Double → U-16


31M: U-8 → U-32 → Raw

来源: 每格为该模型与阶段的全局最低观测 MSE。

跨场景稳定性：U-32 平均排名最好

估计器在 24 个 $\text{cell} \times B$ 场景中的平均 MSE 排名

横轴越小越好；右侧数字为并列第一的场景数



来源：Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

来源：黑色菱形表示中位排名；右侧标注第一名次数。

24 个 $\text{cell} \times B$ 场景


- U-32: 平均 3.08
- U-16: 平均 3.33
- U-8: 平均 3.42
- Raw: 平均 5.00

Raw 有 **8 次第一**，但中位排名第 7。

相对 Raw: U 系列整体降低 MSE

相对 Raw 的 MSE 分布

每个点对应一个 cell×B 场景; 0 表示与 Raw 相同, 负值表示更低 MSE



来源: Stage 2 direct real-Pythia run - pythia-grid-20260826T145530Z

U-32 几何平均 MSE
-7.59%


中位绝对偏差
-28.17%

中位重复方差
-2.56%

阶段依赖之一：Pythia-14M

Pythia-14M: MSE 随样本预算 B 的变化

每个点为相应方法在 64 次重复后的均值向量误差；纵轴为对数尺度




来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

初始化: Raw、 $B = 32$ | 早期: Double、 $B = 64$ | 中后期: U-16、 $B = 32$

阶段依赖之二：Pythia-31M

Pythia-31M: MSE 随样本预算 B 的变化

每个点为相应方法在 64 次重复后的均值向量误差，纵轴为对数尺度




来源: Stage 2 direct real-Pythia run · pythia-grid-20260826T145530Z

初始化: U-8、 $B = 32$ | 早期: U-32、 $B = 32$ | 中后期: Raw、 $B = 32$

排序保持接近，差异主要来自误差幅度

各估计器的 Pearson 排序保持度

跨 24 个 cell×8 场景；纵轴聚焦观测区间，箱体表示中位数与四分位范围




来源: Stage 2 direct real-Python run - pythia-grid-20260826T145530Z

Pearson 中位数: U-32 **0.9252**, Raw 0.9182

来源: Double 与 U-2 完全重合; 左图聚焦 Pearson 的主要区间。

估计器的偏差—重复方差位置

每个点为 24 个 cell×8 场景的中位数; 左下方同时降低绝对偏差与重复方差




来源: Stage 2 direct real-Python run - pythia-grid-20260826T145530Z

U-32 相对 Raw: 偏差与重复方差均下降

样本预算：更大并不自动更准

每个 cell×估计器的最低 MSE 所对应样本预算

共 42 个 cell×method 比较；柱高为该 B 成为最低 MSE 的次数



来源：Stage 2 direct real-Pythia run - pythia-grid-20260826T145530Z

42 ↑ cell×method

- $B = 32$: 27 次
- $B = 64$: 6 次
- $B = 128$: 2 次
- $B = 256$: 7 次


结论：当前比较中，增大 B 不保证降低 MSE。

成本：时间随 B 上升，显存随模型规模上升

样本预算与壁钟时间

每个 B 的一次 repetition 同时计算 Raw, Double 与全部 U-M; 时间主要随梯度样本预算增长


Pythia-14M



—●— 初始化 —■— 早期 —▲— 中后期

来源: Stage 2 direct real-Pythia run - pythia-grid-20260826T145530Z


Pythia-31M



样本预算与峰值显存

峰值为每个 $64 \times B$ 的整数倍; 按模型分提供并限制自训练范围


Pythia-14M



来源: Stage 2 direct real-Pythia run - pythia-grid-20260826T145530Z

—●— 初始化 —■— 早期 —▲— 中后期

Pythia-31M




$B = 32$ 中位时间
7.71 s

$B = 256$ 中位时间
12.65 s

时间倍率
1.64×

精度-成本联合: $B = 32$ 是稳健起点



6 个 cell 中 5 个全局最低 MSE 位于 $B = 32$; 唯一例外为 14M early 的 Double、 $B = 64$

后续实验：按使用情境选，而不是追逐单次冠军

使用情境	主估计器	B	配套策略
跨模型统一默认	U-32	32	保留 Raw; 平均排名最佳、成本最低档
初始化	U-8	32	保留 Raw; 两模型平均排名更好
训练早期	U-32	32	14M 专项可用 Double、64
中后期	U-16 / U-32	32	保留 Raw; 31M 中后期 Raw 胜出
最小双方法	U-32	32	加 Raw, 覆盖稳健主线与异质性基线
三方法输出	Raw+U-16+U-32	32	初始化时 U-16 换为 U-8

Double 与 U-2 只保留一个; U-4 主要用于消融。

逐 cell 的观测精度：量级与相关性

模型-阶段	方法	B	MSE	MAE	Pearson
14M-初始化	Raw	32	1.40×10^{-12}	5.88×10^{-8}	.9870
14M-早期	Double	64	3.61×10^{-12}	1.30×10^{-7}	.9445
14M-中后期	U-16	32	9.19×10^{-11}	1.85×10^{-7}	.8232
31M-初始化	U-8	32	3.99×10^{-13}	4.84×10^{-8}	.9930
31M-早期	U-32	32	1.06×10^{-13}	3.20×10^{-8}	.8282
31M-中后期	Raw	32	1.93×10^{-10}	2.63×10^{-7}	.8982

精度范围

MSE: 1.06×10^{-13} 至 1.93×10^{-10}

相关性范围

Pearson: 0.823 至 0.993

带走四句话

- ① **统一默认**: $U-32$ 、 $B = 32$ 。
- ② **阶段化**: 初始化 $U-8$; 中后期 $U-16/U-32$; 始终保留 Raw 。
- ③ **Raw 高异质**: 冠军次数多, 但跨场景中位排名最差。
- ④ $Double \equiv U-2$; 大 B 不保证更准, 且成本更高。

这批数据支持的是**可执行的** estimator selection, 而不是“一个方法统治所有阶段”。



W. Hoeffding.

A Class of Statistics with Asymptotically Normal Distribution.

The Annals of Mathematical Statistics, 19(3), 1948.



S. Biderman et al.

Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling.

Proceedings of ICML, 2023.



P. Molchanov et al.

Importance Estimation for Neural Network Pruning.

Proceedings of CVPR, 2019.



Parameter Importance Project.

Stage 2 direct real-Pythia run: `pythia-grid-20260826T145530Z`.

Internal experiment artifact, 2026.

谢谢

Q&A

默认: **U-32**、 $B = 32$
对照: Raw

完整报告、CSV、图表和分析脚本随 slides 一并交付

附录

方法明细、逐 cell 数值与数据身份

附录 A：完整方法汇总

方法	平均排名	中位排名	第一名次数	几何平均 MSE / Raw
U-32	3.08	3	4	0.9241
U-16	3.33	3	3	0.9242
U-8	3.42	3	5	0.9243
U-4	4.25	4	1	0.9252
Double	4.46	4.5	0	0.9269
U-2	4.46	4.5	0	0.9269
Raw	5.00	7	8	1.0000

U-8 / U-16 / U-32 的几何平均 MSE 彼此只差约 0.02%，因此选择要同时看排名稳定性与阶段适用性。

附录 B: 六个 cell 的最低 MSE 配置

模型	阶段	方法	B	MSE	MAE	Pearson
14M	初始化	Raw	32	1.40×10^{-12}	5.88×10^{-8}	.9870
14M	早期	Double	64	3.61×10^{-12}	1.30×10^{-7}	.9445
14M	中后期	U-16	32	9.19×10^{-11}	1.85×10^{-7}	.8232
31M	初始化	U-8	32	3.99×10^{-13}	4.84×10^{-8}	.9930
31M	早期	U-32	32	1.06×10^{-13}	3.20×10^{-8}	.8282
31M	中后期	Raw	32	1.93×10^{-10}	2.63×10^{-7}	.8982

附录 C：为什么 Double 与 U-2 重合？

当 $M = 2$ 时,

$$\hat{I}_{U,2} = \frac{(\bar{g}_1 + \bar{g}_2)^2 - \bar{g}_1^2 - \bar{g}_2^2}{2} = \bar{g}_1 \bar{g}_2$$

而 Double 定义为

$$\hat{I}_{\text{Double}} = \bar{g}_A \bar{g}_B.$$

数值核验

- 最大 MSE 差: 2.58×10^{-26}
- 最大 MAE 差: 0
- 最大 Pearson 差: 1.11×10^{-16}

结论：二者仅保留一个正式输出，另一项用于不变量检查。

附录 D：数据身份与可复现入口

字段	值
Run ID	pythia-grid-20260826T145530Z
Main sweep artifact	ff84d8032113da703753282ba1ebdfe9b08bfbb7f36818988870d252ed2b4d4e
Profiler artifact	f33160b33c7a2b3b5afd275243d05e5fb4a48b24d42c3b5ac58e1d14e1174879
Delivery hash	730bf865d2b4eaf60f32cce309560db954a54bbfff4a1cbb69d79383b8c6d78f
Analysis payload	44da7d9fecde8847bc88661db2fd9310928e46ba4d7a851b4ff115a43b567325

复现入口: `analysis.py`
派生结果: `data/analysis-summary.json`、`data/*.csv`
覆盖边界: 31M 中后期、 $B = 64$ 为续跑交付汇总 $n = 18$ 。